

《大学计算机基础》实验指导书

BERT 文本分类实验 —— 基于预训练模型的情感分析

一、实验简介

本实验旨在带领学生了解 BERT (Bidirectional Encoder Representations from Transformers) 模型的基本结构与使用方法。

通过本实验，同学们将学习如何使用 预训练好的 BERT 模型 对文本进行特征提取，并在此基础上完成一个情感分类任务。

二、实验目的

理解 BERT 模型的基本结构及其“预训练 + 微调”思想。

学会加载并使用 transformers 库中的预训练 BERT 模型。

掌握文本分类任务中 BERT 的输入格式、训练方法与预测过程。

通过情感分析实例，体验 BERT 模型在中文语义理解上的强大能力。

三、实验环境

依赖库：

```
pip install pandas torch transformers scikit-learn tqdm
```

请自己进行环境配置，若无法连接到 bert-base-Chinese，本地保存了一个 bert-chinese 文件夹可供使用

四、实验数据

数据集：hotel.csv（酒店评论情感数据集）

数据格式：包含两列

Comment：酒店用户评论文本（如 “房间干净，服务好”）。

Label：情感标签（0 表示负面评价，1 表示正面评价）。

五、实验步骤

步骤 1：理解实验代码结构

提供的代码包含 4 个核心部分，需补全实现：

`load_data`：加载数据集。

`CommentDataset`：自定义数据集类，处理文本编码。

`train_model`：模型训练循环。

`main`：主函数，串联整个流程。

步骤 2：补全数据加载函数（`load_data`）

任务：从 `hotel.csv` 中读取数据并返回 `DataFrame`。提示：使用 `pandas.read_csv` 函数。

步骤 3：补全数据集类（`CommentDataset`）

任务：将文本转换为 BERT 可识别的输入格式（`input_ids` 和 `attention_mask`）。使用 `tokenizer` 对文本进行编码，设置 `padding="max_length"` 和 `truncation=True` 确保文本长度统一。

步骤 4：补全模型训练函数（`train_model`）

任务：实现模型训练的核心循环（前向传播、损失计算、反向传播、参数更新）。

步骤 5：补全主函数（`main`）

任务：初始化 `tokenizer` 与模型。

（如实在遇到困难可查看 `out.py`）

六：预期结果：

文本：酒店位置很好，服务态度也不错，房间干净。

预测标签：1

文本：早餐非常难吃，服务员态度也不好。

预测标签：0

文本：交通方便，地铁口出来就到，下次还会住。

预测标签：1

文本：房间又小又脏，空调坏了，体验极差！

预测标签：0

文本：价格公道，性价比高，推荐入住！

预测标签：1

文本：前台人员不热情，等了半小时才给房卡。

预测标签：0

如遇错误的预测标签可通过增加迭代次数，增加记录 F1 值等修改方式加强预测能力。出现预测错误的情况很正常，希望大家通过本实验学习到思路。